DEEP LEARNING JP
[DL Papers]

LEACL: LLM-Enhanced Automatic Curriculum Learning for Reinforcement Learning in Long-Horizon Manipulation Tasks

Yongdong Wang
Intelligent Robotics and Control Lab (Matsuno Toda Wang Lab)
Real World Robot Informatics Lab (Yamashita An Hamada Lab)





書誌情報

- LEACL: LLM-Enhanced Automatic Curriculum Learning for Reinforcement Learning in Long-Horizon Manipulation Tasks
- LEACL: 長期ホライズン操作タスクの強化学習に向けた、LLMで強化した自動カリキュラム学習
  - Paper: arXiv:2607.23515 (2026)
  - Code: https://github.com/fheravi/LIBERO-plus (LIBERO+)
- 著者: Faraz Heravi[1]*, James Ouyang[1]*, Zifan Xu[1], Arjun Kumar[1], Yoonchang Sung[2], Peter Stone[1,3]
  [1]The University of Texas at Austin, [2]Nanyang Technological University, [3]Sony AI (*equal contribution)
- 特に断りのない限り，図表等の出典は本論文からの引用

本論文の要点
LLMでタスク分解＋メタタスク生成を行い、自動カリキュラム学習（ACL）に接続
密な報酬（dense reward）の設計が不要、スパース報酬のみで長期ホライズン操作を学習
LIBERO+の5タスクで、人手設計の密報酬ベースライン（LEAGUE）を上回る成功率

提案

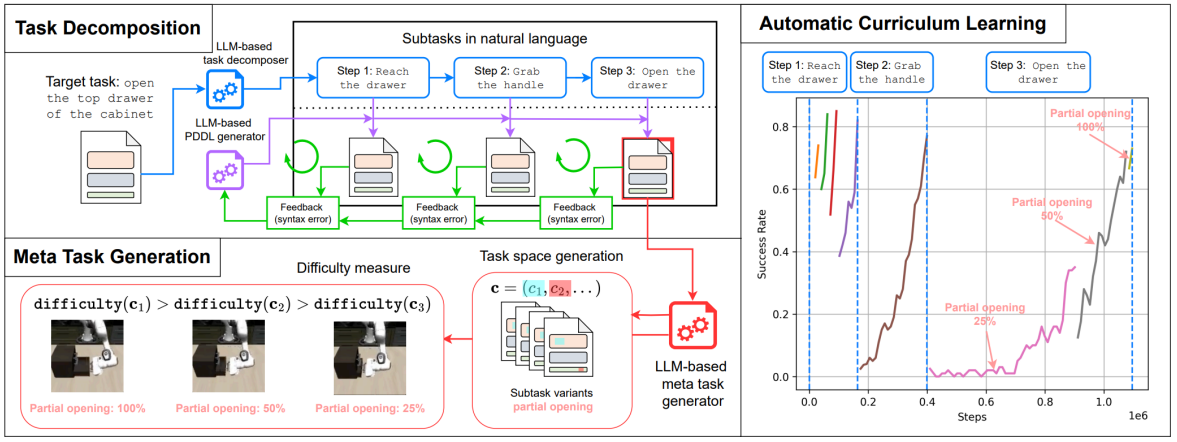


Fig. 1: LEACL stages: (1) LLM-based task decomposition; (2) LLM-based meta-task generation; (3) Automatic CL.

- LEACL：LLMと自動カリキュラム学習（ACL）を統合したフレームワーク
  - 3段階の構成
    - LLMによるタスク分解：長期タスクをPDDL仕様のサブタスク列へ
    - LLMによるメタタスク生成：タスクパラメータ空間と難易度尺度を生成
    - ACL：既存アルゴリズムを差し替え可能な形で接続し学習
- フレームワークの特徴
  - 密な報酬（dense reward）の手設計が不要
  - スパース報酬のみで長期ホライズン操作を学習
- 評価
  - LIBERO+（LIBEROを拡張）上の5つの長期操作タスク
  - 密報酬ベースラインLEAGUEを4/5タスクで上回る
  - 人手設計カリキュラムに匹敵する成功率
    - 例：ketchup配置 89.4% vs 人手 86.3%

背景

- 長期ホライズン操作タスク（例：マグを電子レンジに入れて扉を閉める）は強化学習にとって難しい
  - 完了時のみ報酬が得られるスパース報酬設定では、長い行動系列を偶然成功させる必要があり探索が困難
  - 高次元・連続な状態空間では、サンプル効率が極端に悪化する

- **解決策1：密な報酬（dense reward）の設計**
  - 人手で報酬を整形すれば学習は進むが、コストが大きい
  - 物体の形状・力学の違いで最適な報酬が変わり、汎用性が低い
  - 完了報酬との重み付けが難しく、過度な整形は「雑な」振る舞いを誘発
  - 真の目的とズレてタスク失敗を招く場合もある

- **解決策2：自動カリキュラム学習（ACL）**
  - 易しいタスクから難しいタスクへ訓練分布を自動調整し、サンプル効率を改善
  - 課題：タスク依存の設定が人手依存
    - タスクパラメータ空間（初期姿勢など）
    - 難易度尺度（タスクの順序付け）
    - 高次元な相互作用では設計が特に困難

本研究の問い：報酬の手設計もタスク依存設定の人手作業もなしに、長期ホライズン操作タスクを学習できるか？

関連研究

- **LLMによる計画・意思決定**
  - 自然言語指示から行動計画を生成する研究が急速に進展
  - Code as Policy：LLMが制御方針を直接生成。解釈性は高いが実行時のロバスト性・汎化に課題
  - LEAGUE++：LLMでタスク分解・記号オペレータ生成・密報酬生成
  - Text2Reward / ARCHIE / CurricuLLM：LLMで密報酬やカリキュラムを生成
  - IKER：VLMで視覚キーポイントから報酬を導出（スキル連結が主眼）
  - **共通課題：密な報酬の設計・生成への依存が残る**
- **強化学習のためのカリキュラム学習**
  - 初期は人手設計のタスク列。近年のACLは訓練分布を適応的に調整
  - ALP-GMM、PLR、ADRなど：学習履歴からタスク分布を更新
  - 課題：タスクのパラメータ化と難易度尺度の設定に敏感
  - LLMで直接カリキュラムを生成する研究（Minecraft、Eurekaverse）もあるが、条件分岐を書き込んだプロンプトへの依存が強い
- **本研究の位置づけ**
  - LLMを「メタタスク生成器」として用い、確立されたACL手法に接続する
  - 学習中のLLM問い合わせ回数を抑えられる

→ LEACLの立ち位置：LLMに「報酬」を作らせるのではなく、「ACLが使えるタスク依存仕様」を作らせる

提案と貢献

- **提案：LEACL（LLM-Enhanced Automatic Curriculum Learning）**
  - LLMによるタスク分解とメタタスク生成を、既存のACLアルゴリズムに接続する枠組み
  - 密な報酬を一切設計せず、スパースな完了報酬のみで長期ホライズン操作を学習
- **貢献1：人手作業を排した新しいLLM×ACL枠組み**
  - LLMが「カリキュラムそのもの」ではなく「タスク依存の仕様」（パラメータ空間・難易度尺度）を生成
  - 報酬設計・タスク空間設計いずれの人手作業も不要
- **貢献2：実験による有効性の検証**
  - ACLなしのベースラインに対し、サンプル効率と収束後の成功率で大幅に優位
  - 人手設計に依存するベースライン（Human curriculum）に匹敵する性能
- **貢献3：ベンチマーク拡張 LIBERO+ の公開**
  - LIBEROにパラメータ化述語を追加し、カリキュラム学習に対応

→ 要点：LLMの出力先を「報酬関数」から「タスク依存仕様（パラメータ空間・難易度尺度）」へ移す

手法

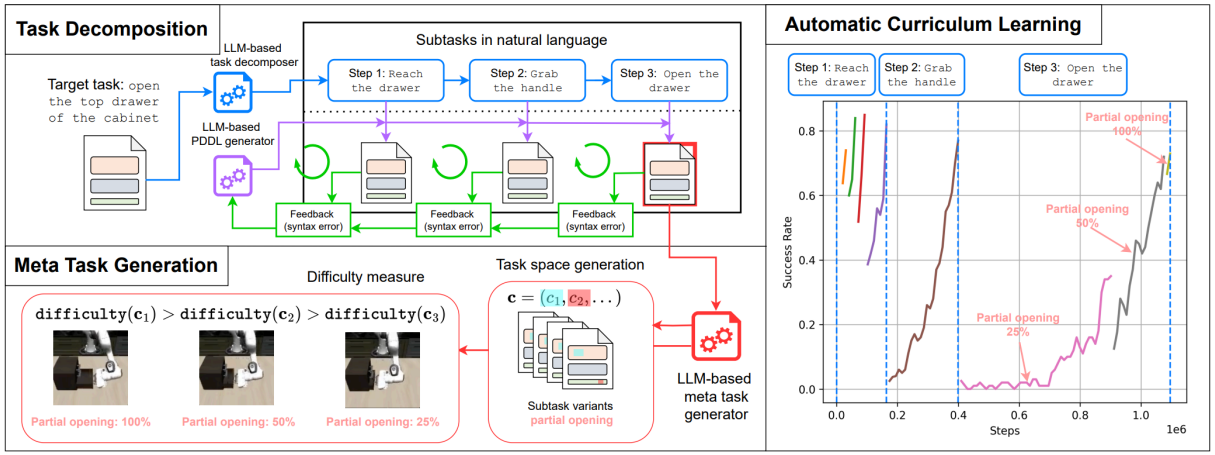


Fig. 1: LEACL stages: (1) LLM-based task decomposition; (2) LLM-based meta-task generation; (3) Automatic CL.

- **LEACLは3段階を順に実行する**
  - ① LLMによるタスク分解：長期タスクを意味のあるサブタスク列に分解し、各サブタスクをPDDL仕様として表現
  - ② LLMによるメタタスク生成：各サブタスクについて、タスクパラメータ空間と難易度尺度（タスク依存の仕様）を生成
  - ③ プラグアンドプレイなACL：生成された仕様を用い、既存ACLアルゴリズムがスパース報酬のみでサブタスクを解く
- K個のサブタスクを順に解き、それらを連結して目標タスクの解とする

問題定義

環境の構成要素
- M：可動物体（ボウル、カップなど）
- F：固定物（キッチン台、キャビネットなど）
- R：物体を置ける領域
- ロボットは物体を把持し、固定物上の領域に置く

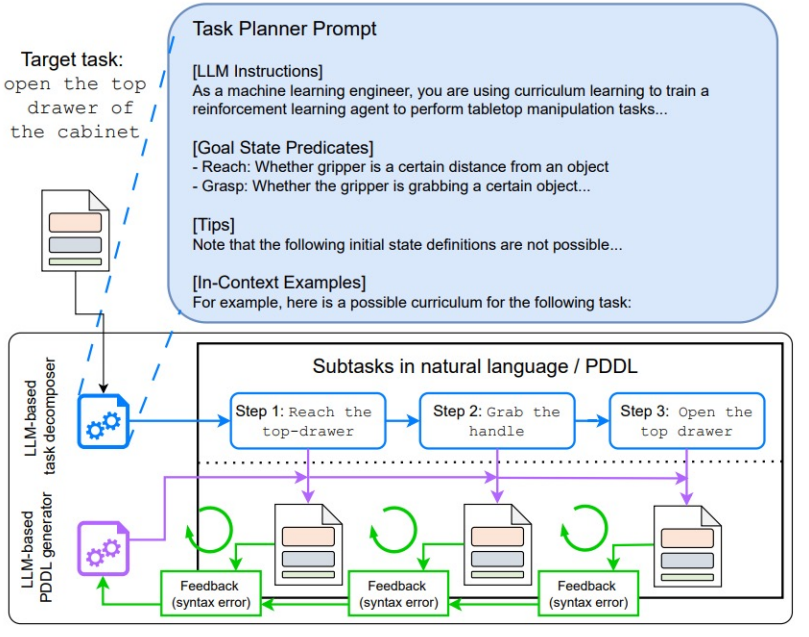
MDPとしての定式化
- 完全観測を仮定し、有限ホライズンの目標拡張MDPとして扱う
- $M = \langle S, A, T, \mu, R, S_G \rangle$
- S：ロボットと環境の状態／A：エンドエフェクタ姿勢
- S_G：タスク完了とみなす状態集合

スパース報酬設定
- 状態が S_G に入ったときのみ $R = 1$、それ以外は 0
- 完了と同時にエピソード終了 → 最大報酬は 1
- 報酬整形（dense reward）は一切用いない

対象タスクと目的
- 対象：物体を領域間で移動させ、かつ接触の多い操作を伴うタスク（引き出しを開ける、電子レンジを閉める、コンロを点ける）
- 目的：タスクの目標を表す自然言語を入力として、期待収益を最大化する方策 π を学習する

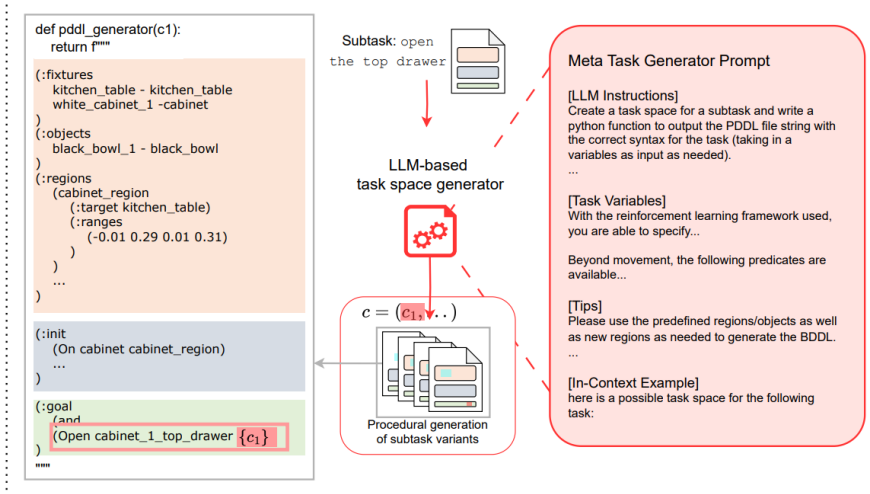
手法

- **① LLMによるタスク分解**
  - 長期タスクを意味のあるサブタスク列へ分解し、中間的な学習信号を得る（TAMP研究に着想）
  - 各サブタスクをPDDL仕様として記述
  - 二階層のプロンプト戦略
    - 上位：目標タスク（自然言語）→ サブタスク列（各々が単一行動）
    - 下位：各サブタスク → 妥当なPDDL仕様へ変換
  - 構文検証と反復修正（reflection）で妥当性・実行可能性を担保
- **PDDL仕様 τi = ⟨M, F, R, Pi, Ii, Gi⟩**
  - Pi：述語集合。例 Open(drawer, 0.3) は0.3m以上開いていれば真
  - 述語の全体集合が「文法」を構成。LLMには対象領域（LIBERO+）の述語語彙を与える
  - Ii / Gi：初期リテラルと目標リテラルの連言
  - M, F, R は全サブタスクで共通（プロンプトで明示的に制約）
  - サブタスク数 K はLLMが動的に決定



手法

- **② LLMによるメタタスク生成**
  - タスク分解だけでは、接触の多いサブタスクをスパース報酬で解くのは依然難しい
  - 先行研究はLLMに密報酬を生成させたが、多様なタスクへの汎用性に乏しい
  - LEACLはLLMに「タスク依存の仕様」を生成させ、既存ACLを使える形にする
- **(a) タスクパラメータ空間**
  - PDDL仕様 τi から Ni 次元のパラメータベクトル ci を定義（制御空間 Ci）
  - ci ∈ Ci が仕様 τi の1インスタンスを決める
    - 例「引き出しを開ける」→ キャビネットの初期位置、目標の開き幅
  - LLMは Ci から妥当なPDDL仕様の部分集合 Ti への生成関数を、Python関数テンプレートとして出力
- **(b) 難易度尺度**
  - 難易度順に並んだ D 個のパラメータベクトル $(c^1_i, \cdots, c^{(D)}_i)$ をLLMに生成させる
  - $p > q$ ならば $c^{(p)}_i$ は $c^{(q)}_i$ より難しい、という順序を表す
  - 易→難で学習を進めることで、難しいタスクの学習効率が向上



手法

- **③ 自動カリキュラム学習（ACL）**
  - エージェントの学習履歴から、訓練タスクの分布を適応的に選択する
    - ALP-GMM：過去のエピソード報酬を利用　／　PLR：TD誤差を利用
  - 目的：訓練後のエージェントが元のサブタスク Mi で高い成功率を達成すること
- **必要となるタスク依存仕様はアルゴリズムごとに異なる（次ページ 表I）**
  - ADR・SPDL：難易度尺度が必須（REQ.）
  - ALP-GMM・RIAC など：タスクパラメータ空間は任意（OPT.）
- **プラグアンドプレイ設計**
  - TeachMyAgent フレームワーク上に実装し、多様なACL手法を差し替え可能
  - 本論文では ADR（Active Domain Randomization）を採用。単純だが、適切な事前情報があれば十分に有効
  - K個のサブタスクを順に解き、それらを集約して目標タスクの解とする

手法

- **表I：各ACLアルゴリズムが必要とするタスク依存仕様（任意=OPT. / 必須=REQ.）**

ACLアルゴリズム	タスクパラメータ空間	難易度尺度
ADR [32]	任意	必須
ALP-GMM [30]	任意	任意
COVAR-GMM [33]	任意	任意
GOAL-GAN [34]	任意	任意
RIAC [35]	任意	—
SPDL [36]	任意	必須
SETTER-SOLVER [37]	任意	任意

- LEACLはこの2つのタスク依存仕様をLLMに自動生成させるため、多くのACL手法をそのまま利用できる
- 本論文では難易度尺度を必須とする ADR を採用

手法

- **LEACL 全体の流れ（3段階を逐次実行）**

① LLMによるタスク分解

・目標タスク（自然言語）を入力
・サブタスク列を生成
・各サブタスクをPDDL仕様 τi に変換
・構文エラーをフィードバックし反復修正

② LLMによるメタタスク生成

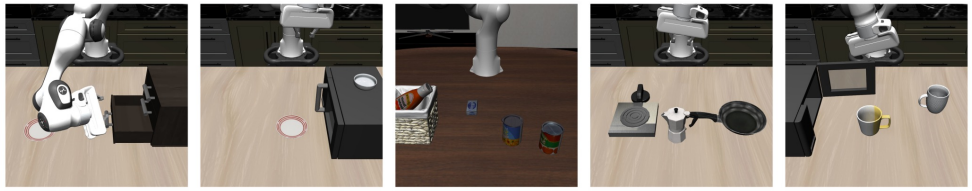
・各サブタスクのタスクパラメータ空間 Ci を定義
・PDDL生成関数（Python）を出力
・難易度順のパラメータ列を生成

③ ACL（本論文はADR）

・パラメータ空間上で訓練分布を適応調整
・スパース報酬のみでPPOを学習
・K個のサブタスクを順に解き集約

→ 人手が必要なのは「述語の文法（LIBERO+の述語集合）」のみ。密な報酬関数もタスク依存設定も人手設計なしで長期ホライズン操作を学習できる

実験セットアップ



Task 1: *open the bottom drawer of the cabinet.* | Task 2: *put the white bowl on the plate.* | Task 3: *pick up the ketchup and put it in the basket.* | Task 4: *turn on the stove and put the moka pot on it.* | Task 5: *put the mug in the microwave and close it.*

Fig. 4: Front camera views of the five evaluation tasks.

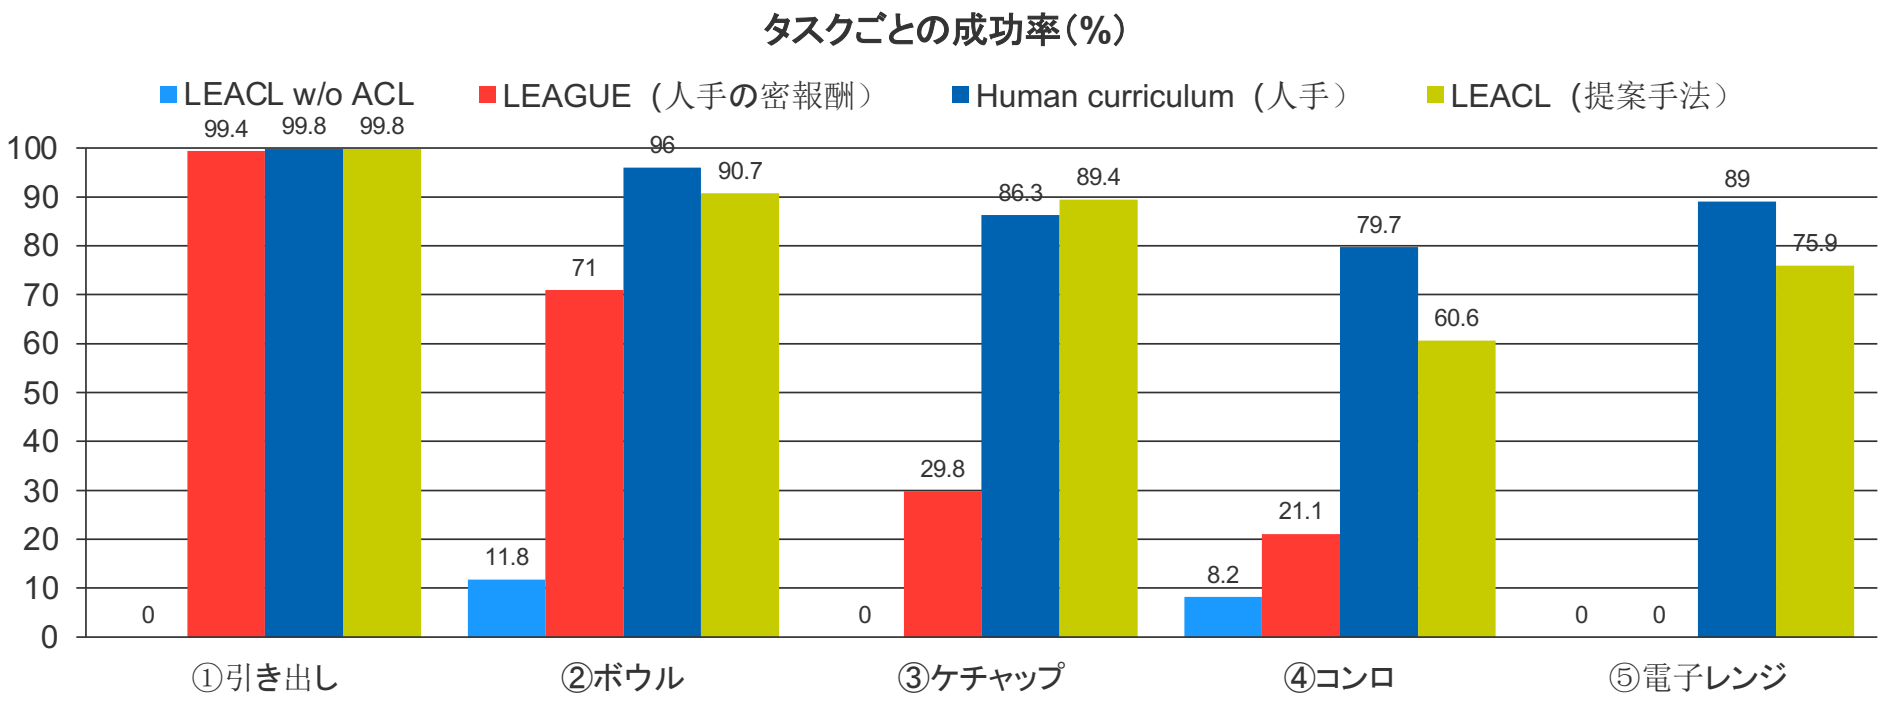
- **LIBERO+：CL向けに拡張したベンチマーク（公開済み）**
  - LIBERO（生涯学習用ベンチマーク、MuJoCo）はCL設定には機能不足
  - 述語を「パラメータ化」した版に置換：open(object) → open(object, ?o)
  - 新たな述語も追加し、連続値パラメータを扱えるように
  - より多様なタスク・PDDL仕様を手続き的に生成可能
- **評価タスク（5種、長期ホライズン操作）**
  - ① キャビネットの下段引き出しを開ける（サブタスク2）
  - ② 白いボウルを皿の上に置く（5）
  - ③ ケチャップを持ち上げてカゴに入れる（6）
  - ④ コンロを点けてモカポットを置く（4）
  - ⑤ マグを電子レンジに入れて閉める（5）
- **学習設定**
  - ベースRL：PPO（Stable-Baselines3ベース、lr=2e-4、512ステップ/更新、MLP 128×2）
  - LLM：ChatGPT 4o-mini／ACL：ADR
  - 各タスク5シード、最終モデルで1,000エピソード評価

結果

手法	①引き出しを開ける	②ボウルを皿に	③ケチャップをカゴに	④コンロ点火＋モカポット	⑤マグを電子レンジに入れ閉める
Sparse reward	0.0	0.0	0.0	0.0	0.0
LEACL w/o ACL	0.0	11.8	0.0	8.2	0.0
LEAGUE（人手の密報酬）	99.4	71.0	29.8	21.1	0.0
Human curriculum（人手）	99.8	96.0	86.3	79.7	89.0
LEACL（提案手法）	**99.8**	**90.7**	**89.4**	**60.6**	**75.9**

- **成功率（%）：5シードの平均、最終モデルで1,000エピソード評価（表II）**
  - LEACLは Sparse reward・LEACL w/o ACL を全タスクで大きく上回る
  - 人手の密報酬を用いる LEAGUE を 4/5 タスクで上回る（③は89.4 vs 29.8）
  - 上限とみなせる Human curriculum にも匹敵（③では上回る）

アブレーション実験結果



- **ACLを外すとほぼ全タスクで失敗（LEACL w/o ACL）→ タスク分解だけでは短いサブタスクすら解けない**
- Sparse reward のみ（分解もACLもなし）は全タスク 0.0%（図では省略）
- 密報酬を用いる LEAGUE は4/5タスクでLEACLに劣る → 密報酬の設計・重み付けの難しさ

結果

- **表III：各手法が用いる構成要素の比較（○＝使用、×＝不使用）**

手法	タスク分解	パラメータ化述語	RLで用いる仕様
Sparse reward	×	×	スパース報酬RL
LEACL w/o ACL	○	×	スパース報酬RL
LEAGUE	○	×	密報酬RL
Human curriculum	○	○	RL + 人手 + ACL
LEACL（提案手法）	○	○	**RL + LLM + ACL**

- LEACLとHuman curriculumのみがパラメータ化述語＋ACLを利用
- 両者の違いはタスク分解とメタタスク生成をLLMが行うか人手で行うかのみ
- LEAGUEは分解は行うが、各サブタスクに人手の密報酬を必要とする

結果

- **① タスク分解だけでは短いサブタスクすら解けない**
  - 「引き出しに手を伸ばす」→「ハンドルを掴む」のように分解しても、後者はスパース報酬だけでは困難
  - LEACL w/o ACL はほぼ全タスクで失敗（最良でも 白いボウルを皿に で 32.8%）
- **② 長期ホライズン操作の整形報酬（shaping reward）設計は難しい**
  - タスク固有のチューニングが必要で、物体の形状・力学によって効果が大きく変わる
  - 例：持ち上げ報酬をグリッパ高さで定義するか物体高さで定義するかで挙動が変わる
  - 密報酬と完了報酬の重み付けも難しく、過大だとタスク成功を軽視する挙動になる
  - 完了報酬のみ＋成功時の早期終了の方が、精密で信頼できる操作が得られた
- **③ カリキュラム生成においてLLMは人間の専門家に匹敵する**
  - Human curriculum は 3/5 タスクで LEACL を上回るが、専門家が何度も反復設計する必要がある
  - LEACLは適切なプロンプトさえあれば、ゼロショットで有効なタスク空間を生成できる

→ まとめると
・スパース報酬＋ACLの組み合わせが、密報酬の設計より頑健で精密な方策を生む
・LLMは「カリキュラムの設計者」として人間の専門家に十分置き換わりうる

まとめ

- **本論文の貢献**
  - LLMとACLを統合した新しい枠組み LEACL を提案し、手作業なしにスパース報酬のみで長期ホライズン操作を解けることを示した
  - ACLなしのベースラインに対しサンプル効率と収束後の成功率で優位、人手設計に依存するベースラインとも競合的な性能
  - CL向けに拡張したベンチマーク LIBERO+ を公開（パラメータ化述語の追加）
- **位置づけ・示唆**
  - LLMの使い方を「報酬生成」から「タスク仕様生成」へずらすことで、報酬設計のバイアスを回避
  - プロンプト設計の負担が小さく、LLMの呼び出し回数も学習中に増えない
  - 既存の多様なACL手法をそのまま流用できる（本論文はADRを採用）

本論文の限界と議論

- **著者が挙げる最大の限界：述語文法の事前定義への依存**
  - タスク分解に使う述語集合（LIBERO+の全述語）を事前に与える必要がある
  - 新しい対象物・新しい相互作用には述語の追加という人手作業が残る
- **その他の気になる点**
  - 人手カリキュラムには3/5タスクで劣る（特に④コンロ＋モカポット 60.6% vs 79.7%）
  - ACLはADRのみで評価。ALP-GMMやPLRなど他手法での検証は今後の課題
  - LLMはChatGPT 4o-miniのみ。生成の当たり外れ（分散）の議論は限定的
  - シミュレータ（MuJoCo / LIBERO+）のみで、実機検証はない
  - サブタスクは逐次的に解かれるため、失敗のリカバリや再計画は扱っていない

今後の展望

- **著者が示す方向性**
  - 述語文法の自動生成：LLMにタスク固有の文法（述語集合）を提案させ、事前定義への依存を解消する
- **発展が考えられる方向**
  - ACL手法の拡張：ALP-GMM・PLR・SPDLなどとの比較、難易度尺度の質の評価
  - サブタスク間の方策の統合・スキル連結、失敗時の再計画への拡張
  - 視覚入力（画像・VLM）への拡張。現状は低次元の物体状態を前提
  - 実機への転移（sim-to-real）と、接触の多い操作でのロバスト性検証
  - LLMの選択・プロンプトに対する感度分析と、生成失敗時のフォールバック設計

再現実験：公開部分（単一タスクPPO）の実行例



成功例：ドアを閉める

公開リポジトリの単一タスク PPO を A6000 で学習。30万ステップ後の方策がドアを押し込んで閉める（12s）



成功例：ケチャップを掴む

サブタスク単位の方策の例。LEACL の「サブタスクごとに1つの PPO」という粒度に対応（2.2s）



失敗例：閉まらない

ドア上を長時間徘徊し、最後まで閉め切れない。学習不足の典型（42s）



失敗例：行動が逸れる

自作の変体タスク。ドアではなくカップを掴みに行き、カップを弾いて終了（21s）

疎報酬（成功=1/失敗=0）のみでは方策が迷走 → カリキュラムを導入する動機。※再現したのは公開部分（単一タスク PPO）のみで、LLM 課程パイプラインは未公開のため未再現。

参考文献

本論文

- F. Heravi, J. Ouyang, Z. Xu, A. Kumar, Y. Sung, P. Stone, “LEACL: LLM-Enhanced Automatic Curriculum Learning for Reinforcement Learning in Long-Horizon Manipulation Tasks,” arXiv:2607.23515, 2026.
- コード：https://github.com/fheravi/LIBERO-plus

主要な関連研究

- [6] R. Portelas et al., “TeachMyAgent: a Benchmark for Automatic Curriculum Learning in Deep RL,” ICML 2021.
- [9], [11] LEAGUE / LEAGUE++：LLMによるタスク分解・記号オペレータ生成と密報酬生成
- [30] R. Portelas et al., “Teacher algorithms for curriculum learning of deep RL in continuously parameterized environments (ALP-GMM),” CoRL 2019.
- [31] M. Jiang et al., “Prioritized Level Replay (PLR),” ICML 2021.
- [32] B. Mehta et al., “Active Domain Randomization,” CoRL 2020.
- [38] B. Liu et al., “LIBERO: Benchmarking Knowledge Transfer for Lifelong Robot Learning,” NeurIPS 2023.
- [39] E. Todorov et al., “MuJoCo: A physics engine for model-based control,” IROS 2012.
- [41] J. Schulman et al., “Proximal Policy Optimization Algorithms,” arXiv:1707.06347, 2017.
- [42] A. Raffin et al., “Stable-Baselines3,” JMLR 2021.
- [20] Text2Reward / [21] ARCHIE / [22] CurricuLLM：LLMによる報酬・カリキュラム生成
- [24] Voyager（Wang et al.）/ [25] Eurekaverse：LLMによるカリキュラム・環境生成